

Дообучение NanoVLM для управления агентом в среде MiniGrid EmptyEnv

Игорь Павлов

Репозиторий: [ссылка на гитхаб](#)

Аннотация. В работе исследуется адаптация компактной vision-and-language модели NanoVLM для управления агентом по частичному RGB-наблюдению в MiniGrid EmptyEnv. Сравниваются supervised fine-tuning на экспертных траекториях, GRPO с прямым выводом действия и GRPO с генерацией краткого текстового плана. Методы оцениваются по success rate, return, доле некорректных ответов и sample efficiency. GRPO-action быстро достиг 100% success rate и затем сокращал траектории, тогда как text+action оказался менее устойчивым.

1. Постановка задачи

В каждый момент времени агент получает частичное RGB-изображение наблюдаемой области и должен выбрать одно из трех действий: **left**, **right** или **forward**. Цель эпизода — достичь зеленой клетки за ограниченное число шагов. В качестве основной среды используется MiniGrid-Empty-Random-6x6-v0; положение агента и его ориентация изменяются между эпизодами.

Мы сравниваем три режима:

1. **SFT**: предсказание следующего действия по экспертным примерам;
2. **GRPO-action**: RL-дообучение с генерацией одного action-слова;
3. **GRPO-text+action**: генерация двух коротких предложений о состоянии и плане, после которых последним словом указывается действие.

Во всех режимах изображение обрабатывается штатным image processor NanoVLM (он делит изображение на блоки). Исполняемое действие определяется по последнему слову ответа. Ответы, которые не заканчиваются допустимым действием, считаются некорректными.

2. Эксперт и датасет

2.1. Экспертная политика

Основной датасет собирался с эвристическим экспертом **visible_goal_clockwise**. Если зеленая цель присутствует в частичном наблюдении, эксперт выбирает первый шаг кратчайшего доступного маршрута к ней. Если цель не видна, агент поворачивается направо. Такая политика дает детерминированную стратегию и в случае, если цель видна, и в случае, если она не видна. Использовать **shortest_path** эксперта не является хорошей стратегией, поскольку с точки зрения наблюдателя за состоянием в случайной конфигурации, когда цель не видна, он движется равновероятно вправо или влево, что не очень хорошо для нашего агента, поскольку в таком случае он может застрять надолго, поворачиваясь то вправо, то влево, не находя цель.

Дополнительно реализован эксперт **partial_observation_wall_follow**, который использует только видимое наблюдение и применяется на картах от 5x5 до 16x16. Он действует по следующему алгоритму:

1. Если цель видна, двигаться к ней кратчайшим путем.
2. Иначе, если видно, что карта маленькая (одна из сторон целиком помещается в наблюдении) то повернуть направо. Сделано для того, чтобы попытаться удачу, возможно цель окажется справа.
3. Иначе, если перед агентом открытая клетка, двигаться вперед.
4. Иначе, если не смотрим в угол, то повернуться в сторону, в которой меньше клеток в наблюдении (если одинаково, то вправо)
5. Иначе, если смотрим в угол, то повернуть в направлении, где есть свободные клетки.

Этот агент нужен для проверки переноса на более разнообразные размеры среды, но основной контролируемый эксперимент проводится на карте 6x6 со случайной начальной позицией. Также для данного агента можно доказать, что при такой стратегии невозможно заикливание и зеленая клетка рано или поздно будет достигнута. В дополнительном SFT-эксперименте с траекториями **partial_observation_wall_follow** также была достигнута идеальная validation action accuracy.

2.2. Сбор и формат данных

Каждый пример содержит PNG-изображение наблюдения, текстовый prompt и целевое слово (действие) или же последовательность слов + действие в случае text+action. Данные разделяются на train и validation в отношении 90/10. Статистика основного набора приведена в табл. 1.

Table 1: Статистика экспертного датасета. Три варианта prompt/target используют одни и те же траектории.

Показатель	Значение
Число экспертных эпизодов	1000
Число observation–action пар	4576
Средняя длина эпизода	4.576
Средний return эксперта	0.9714
Доля left / right / forward	0.057 / 0.258 / 0.685
Train / validation split	90% / 10%

3. Методы обучения

3.1. Supervised fine-tuning

Модель обучается предсказывать экспертный ответ по частичному RGB-наблюдению размера 7×7 и текстовому prompt с помощью стандартной авторегрессионной функции потерь NanoVLM. Во всех сравниваемых запусках обновляется только modality projector. Используются AdamW с learning rate $5 \cdot 10^{-5}$, batch size 16 и mixed precision в формате bfloat16. Обучение останавливается после трех последовательных validation-оценок с action accuracy не ниже 0.99.

Помимо baseline проверяются два улучшения:

- **Policy prompt:** в prompt явно описывается поведение эксперта: поиск цели правым поворотом и кратчайшее движение к видимой цели;
- **Мягкая балансировка:** частые действия прореживаются так, чтобы доля редкого left достигала 15%, без искусственного oversampling.

3.2. GRPO

Обе политики стартуют с намеренно недообученных SFT checkpoints, чтобы после SFT оставалось пространство для RL-улучшения. Action-only warm start имеет success rate 0.50, text+action — 0.74. На каждом update используются четыре стартовых состояния и четыре траектории на состояние, то есть 16 эпизодов среды. Вознаграждения нормализуются внутри каждой группы, а целая функция сочетает clipped policy loss и KL-регуляризацию к замороженной SFT-модели ($\beta = 0.04$). Некорректный ответ получает штраф -1 . В GRPO мы также обучали только modality projector.


В action-only режиме модель генерирует один токен. В text+action она пишет два коротких предложения о наблюдении и плане, а последнее слово интерпретируется как действие. Остальные параметры, train/eval seeds и частота оценки совпадают. Action-only обучался 300 updates, text+action — 150: длинная авторегрессионная генерация делала один text+action update примерно в семь раз дороже. Поэтому основное сравнение проводится при общем бюджете 150 updates (2400 эпизодов), а результат action-only после 300 updates приводится отдельно.

4. Экспериментальные результаты

4.1. SFT и улучшения

Table 2: Сравнение вариантов SFT на общем validation-наборе и фиксированных rollout seeds.

Вариант	Шаг до success=1	Шаг до acc. 0.99	Шаг до parse=1	Return
Action prompt	240	510	60	0.971
Policy prompt	110	470	70	0.971
Policy prompt + balancing	110	410	70	0.972
Plan + action	300	350	300	0.971



(a) Validation action accuracy по optimizer step для четырех SFT-форматов.

(b) Success rate на фиксированных rollout seeds. На промежуточной оценке использовалось небольшое число эпизодов, поэтому кривая дискретна.

Figure 1: Сравнение четырех вариантов SFT. Все модели обучали только modality projector; optimizer step не отражает дополнительную стоимость длинного plan+action-ответа.

Policy prompt быстрее всего формирует успешное поведение: success rate достигает 1.0 на шаге 110 против шага 240 для базового action prompt. Балансировка сохраняет эту скорость и уменьшает число шагов до accuracy 0.99 с 470 до 410, несмотря на сокращение train-набора с 4118 до 1640 примеров. Plan+action позже достигает успешного rollout (шаг 300), но быстрее остальных достигает accuracy 0.99 (шаг 350). При этом один его optimizer step вычислительно дороже из-за более длинной целевой последовательности. Все четыре модели в финальной оценке достигают success rate 1.0 и близкого return около 0.97, поэтому основное различие состоит в скорости обучения, а не в итоговом качестве. Action-only модели достигают parse rate 1 уже на шагах 60–70, тогда как plan+action требуется 300 шагов из-за более длинного и строгого формата ответа.

4.2. GRPO и sample efficiency




Figure 2: Динамика GRPO по числу rollout-эпизодов. Success, return и длина измеряются каждые 10 updates на 20 фиксированных seed; KL усреднен окном из 10 updates. Text+action ограничен 2400 эпизодами.

Я определяю Sample efficiency, как число дополнительных эпизодов среды до первого наблюдаемого success rate не ниже 0.8. Action-only пересекает порог после 320 эпизодов и уже со следующей оценки стабильно сохраняет success rate 1.0. После насыщения success дальнейшее обучение не пропадает впустую: return растет с 0.953 до 0.965, а средняя траектория сокращается с 7.45 до 5.55

Table 3: Сравнение GRPO. Метрики при 2400 эпизодах получены на одинаковых 20 evaluation seeds. Final eval использует 50 seeds; у action-only он выполнен после 4800 эпизодов, у text+action — после 2400.

Формат	SFT succ.	До 0.8	Succ.@2400	Return@2400	Final succ.	Final return
Action-only	0.50	320	1.00	0.957	1.00	0.962
Text+action	0.74	160*	0.85	0.672	0.78	0.532

шага. Поскольку SFT warm start-ы имеют разное начальное качество, эти числа характеризуют весь пайплайн SFT+GRPO, а не изолированный вклад формата ответа.

Text+action впервые достигает 0.8 после 160 эпизодов, но звездочка в табл. 3 существенна: результат неустойчив. На промежуточных 20-seed оценках success колеблется от 0.70 до 0.85, а final eval на 50 эпизодах дает 0.78. Одновременно оконный KL вырастает примерно до 3.0, тогда как у action-only остается около 0.17. Это указывает, что выбранный коэффициент $\beta = 0.04$ слишком слабо удерживает длинную text+action последовательность рядом с reference policy. Поэтому раннее пересечение порога нельзя трактовать как более высокую устойчивую sample efficiency.

5. Обсуждение и выводы

Основные наблюдения. Среди SFT-вариантов явное описание политики существенно ускорило появление успешного поведения по сравнению с базовым prompt. Мягкая балансировка дала лучший компромисс: сохранила ранний success policy prompt и быстрее достигла идеальной validation accuracy на меньшем наборе данных. Формат plan+action обеспечил высокую accuracy, но потребовал больше шагов до успешного поведения и увеличил стоимость генерации.

В GRPO наиболее убедительным оказался прямой вывод действия. Политика быстро научилась завершать все эпизоды, а затем стала выбирать более короткие маршруты. Text+action получил более сильный SFT warm start и раньше показал success 0.8, но это преимущество не закрепилось: качество колебалось, invalid rate в final eval составил 4.5%, а KL заметно вырос. В текущей конфигурации текстовый план усложнил оптимизацию, но не улучшил ни итоговый success, ни return. Кроме того, один его update был существенно дороже, поэтому при ограниченном вычислительном бюджете action-only оказался практичнее.

Характерные ошибки. Для action-only основной остаточный недостаток — перекошенное распределение действий: на финальном eval модель не использует `right`, хотя успешно решает все эпизоды обходным поведением. У text+action встречаются ответы без корректного последнего действия; кроме того, большой KL сопровождается просадками success и return. Возможны и семантические ошибки, когда текстовый план выглядит правдоподобно, но финальное действие ему не соответствует.

Что попробовать дальше. (1) обучение на больших размерах карты в случайных позициях; (2) подбор или адаптивное изменение KL коэффициента; (3) RGB-аугментации; (4) среды с препятствиями; (5) несколько GRPO seeds и подбор group size. (6) использовать более сложных агентов (в т.ч. `partial_observation_wall_follow`); (7) попробовать сделать reward за согласованность текста и действия; (8) fine-tune не только modality projector (можно использовать LoRA);